Slovenská technická univerzita v Bratislave

Fakulta informatiky a informačných technológií

Umelá inteligencia

Problém obchodného cestujúceho

Artúr Kozubov

Meno cvičiaceho: Ing. Ivan Kapustík

Čas cvičení: Št 18:00

Dátum vytvorenia: 09. 10. 2023

Zadanie úlohy *(c 1,2) Problém obchodného cestujúceho (Travelling Salesman Problem)*

Našou úlohou bolo vyriešiť problém nájdenia najkratšej cesty medzi N mestami.

Muselo sa postupovať dvoma algoritmami:

- Genetický algoritmus
- Zakázané prehľadávanie (tabu search)

Implementačné prostredie

Program je vytvorenej v `Python 3.11.15` a na správne fungovanie sa využíva knižnica `random` a `time` a `sys` a `matplotlib`.

Priebeh programu

Program sa spustí pomocou operátora „-a“ na výber algoritmu:

```
1. use:
2.   python main.py <algorithm> [options]
3. algorithm:
4.   -a [g = genetic, t = tabu-search]
5. options:
6.   -n [int(default=11)]
```

Program bude vypisovať aktuálni hodnoty, ako:

- Aktuálna hodnota (najlepšia (najmenšia) cesta)
- HĺbkA
- Počet vytvorených génov

A graficky zobrazi aktuálny stav:

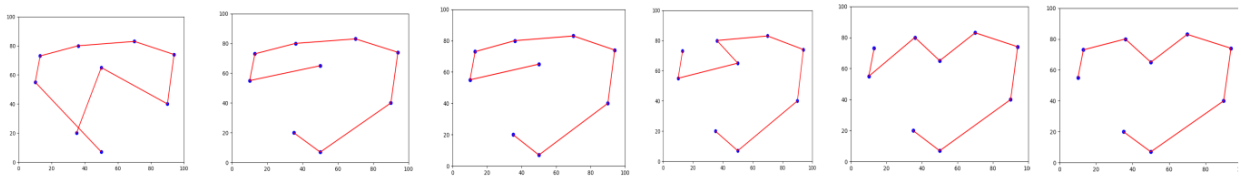

A po ukončeniu aj poradie:

```
1. >Best: 874.95010054318 | Depth: 48 | Gen Gen: 62476011
2. >Order: [44, 29, 47, 9, 42, 50, 11, 25, 16, 39, 12, 0, 30, 17, 43, 2, 4, 31, 26, 22, 8, 35, 28,
1, 23, 27, 21, 32, 14, 19, 40, 38, 37, 20, 7, 49, 46, 5, 24, 34, 45, 3, 33, 15, 48, 13, 36, 18, 41,
6, 10]
```

Algoritmy

Genetický algoritmus

Je heuristický algoritmus inšpirovaný prirodzeným procesom evolúcie. *Evolúcia opisuje zmenu biologických vlastností druhov v priebehu generácií prostredníctvom prirodzeného výberu.*

Výhody:

- Globálna optimalizácia:
  - GA sú schopné nájsť riešenia v komplexných prehľadávacích priestoroch, vďaka čomu sú vhodné pre problémy, kde je priestor riešení málo prehľadný alebo veľmi nelineárny.
- Paralelné spracovanie:
  - GA prirodzene pracujú s populáciou riešení, ktoré sa môžu vyhodnocovať paralelne. To umožňuje efektívne využívať zdroje na paralelné spracovanie.
- Robustnosť:
  - GA sú často robustné v hlučnom prostredí alebo pri nedokonalých hodnoteniach vhodnosti. Je menej pravdepodobné, že sa zaseknú v lokálnom optime.

Nevýhody:

- Výpočtová náročnosť:
  - GA môžu byť výpočtovo náročné, najmä v prípade veľkých problémových priestorov alebo pri použití zložitých fitness funkcií.
- Ladenie parametrov:
  - GA často vyžadujú starostlivé ladenie parametrov, ako je veľkosť populácie, rýchlosť mutácie, rýchlosť kríženia a výberové mechanizmy. Nájsť správny súbor parametrov môže byť netriviálna úloha.
- Žiadna záruka globálneho optima:
- Neexistuje žiadna záruka, že genetický algoritmus nájde globálne optimum, aj keď je navrhnutý na globálnu optimalizáciu. Je možné, že GA bude konvergovať k suboptimálnemu riešeniu.

Algorithm

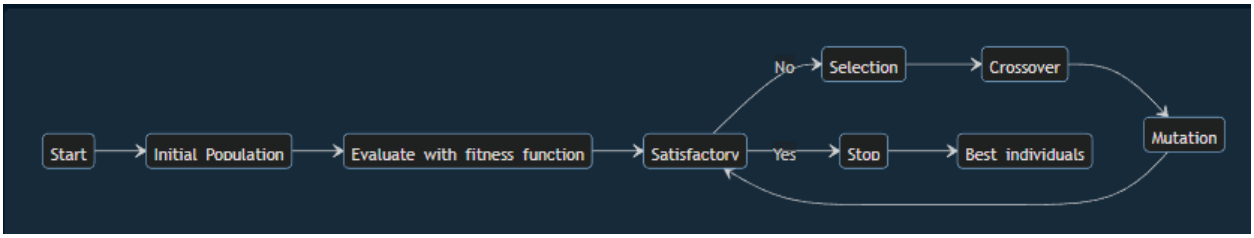

Fitness function

Funkcia, ktorá vyhodnocuje kvalitu riešení.

```
def calcHeuristicValue(state):
    heuristic = 0

    len_of_state = len(state)

    for index in range(len_of_state - 1):
        heuristic += distance(points[(state[index])], points[state[index + 1]])

    return heuristic
```

**Taka ista funkcia je použitá aj pre GA.*

Podarilo sa mi tiež zobraziť riešenia s ich kvalitou v 3d grafike

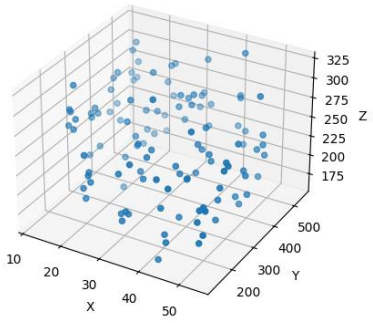

*X,Y - order of cities represented as x and y coordinate. Z - heuristic value.

Crossover

(S najvhodnejšími jedincami) Generujte nových jedincov náhodným krížením ich "riešení" (génov).

V mojom projekte ja používal som Partially - Mapped Crossover (PMX) Goldberg and Lingle (1985)****

Zakázané prehľadávanie (tabu search)

Je heuristický *optimalizačný* algoritmus používaný na riešenie zložitých kombinatorikách optimalizačných problémov.

Základnou myšlienkou je preskúmanie priestoru riešení presunom z jedného riešenia na susedné riešenie.

Výhody:

- Globálna optimalizácia:
  - Tabu Search je efektívne pri hľadaní vysokokvalitných riešení v zložitých nekonvexných priestoroch. Dokáže riešiť problémy s viacerými lokálnymi optimami.
- Odolnosť voči lokálnym optimám:
  - Tabu Search využíva stratégie, ako sú kritériá ašpirácie, ktoré umožňujú pohyby vedúce k lepším riešeniam, aj keď sa nachádzajú v tabu zozname. To pomáha vyhnúť sa uviaznutie v lokálnom optime.
- Zachovanie rozmanitosti:
  - Tabu Search prirodzene skúma širokú škálu riešení vďaka rovnováhe medzi prieskumom a využívaním, čo pomáha predchádzať predčasnej konvergencii k suboptimálnym riešeniam.

Nevýhody:

- Citlivosť na parametre:
  - Tabu Search často zahŕňa ladenie parametrov, ako je tabu tenure, kritériá ašpirácie a veľkosť okolia. Účinnosť algoritmu môže byť citlivá na výber týchto parametrov.
- Výpočtová náročnosť:
  - V závislosti od zložitosti problému a veľkosti priestoru riešení môže byť hľadanie Tabu náročné na výpočty. To môže byť nevýhodou pri rozsiahlych problémoch.
- Obmedzená pamäť:
  - Tabu zoznam v Tabu Search má konečnú kapacitu, čo znamená, že časom môže zabudnúť potenciálne cenné informácie. To môže brániť schopnosti algoritmu uniknúť z lokálneho optima.

Algorithm

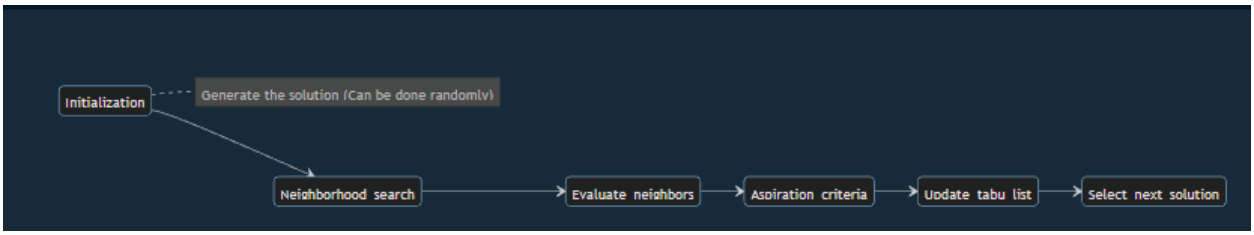

Neighborhood/Neighbors search

Výber štruktúry okolia je špecifický pre daný problém a závisí od povahy optimalizačného problému, ktorý riešite. Ktorý sa snažíte vyriešiť.

Na nájdenie susedov som použil logiku preskupenia dvoch miest v riešení:

```
def getNeighbors(state):
    swapped_arrs = []
    n = len(state)
    for i in range(n - 1):
        for j in range(i + 1, n):
            swapped_arr = list(state)  # Copy the given array.
            swapped_arr[i], swapped_arr[j] = swapped_arr[j], swapped_arr[i]  # Swap the two elements.
            swapped_arrs.append(swapped_arr)  # Add the altered array to the list.
    return swapped_arrs
```

Zhodnotenie riešenia

Možnosti rozšírenia

Genetický algoritmus

Optimalizácia:

- Parametre algoritmu:
  - Je obzvlášť dôležité vyladiť parametre, ako je veľkosť populácie, pravdepodobnosť kríženia, pravdepodobnosť mutácie atď. Optimalizácia týchto parametrov môže výrazne ovplyvniť výkonnosť algoritmu.

Možnosti rozšírenia:

- Elitizmus:
  - Implementujte mechanizmus elitizmu, ktorý umožňuje, aby najlepšie riešenia z predchádzajúcej populácie automaticky prešli do ďalšej generácie.
- Multikriteriálna optimalizácia:
  - Rozšírenie GA na riešenie multikriteriálnych problémov pomocou techník, ako je archív nedominovaných riešení (NSGA) alebo vážený súčet kritérií.
- Hybridizácia:
  - Zváženie hybridizácie GA s inými optimalizačnými metódami alebo heuristikami s cieľom zlepšiť výkonnosť v konkrétnych scenároch.

Zakázané prehľadávanie (tabu search)

Optimalizácia:

- Pomocou rôznych funkcií sa nájdu optimálne susediace riešeniayu.

Možnosti rozšírenia:

- Intenzifikácia a diverzifikácia:
  - Zvážte zavedenie stratégií intenzifikácie (zameranie sa na aktuálne najlepšie riešenie) a diverzifikácie (skúmanie nových oblastí riešenia).
- Adaptívne metódy:
  - Použite metódy adaptácie parametrov, ktoré umožňujú algoritmu dynamicky upravovať svoje parametre počas optimalizačného procesu.
- Multikriteriálna optimalizácia:

Testovanie

Num of cities	Genetic (heuristic/gen gen/secs)	Tabu-search (heuristic/gen gen/secs)
11	268 / 1903 / 3.1416	275 / 3861 / 3.6284
11	318 / 1063 / 4.1544	299 / 386 / 3.631
11	298 / 1399 / 4.6842	270 / 3311 / 3.2925
51	1395 / 58,191 / 11.0477	802 / 573,761 / 42.6795
51	1408 / 24,463 / 8.6952	777 / 6,375,166 / 46.4211
51	1338 / 19,023 / 9.6111	754 / 624,761 / 46.2733
101	3196.8808 / 2,013,871 / 24.0241	1894 / 5,213,415 / 142.23
101	3185.7780 / 145,221 / 25.0509	1609 / 3,787,511 / -

Po analýze grafu môžeme povedať, že algoritmus „tabu-search“ je efektívnejší, ako „genetický“, pretože jeho riešenie je lepšie. Na rozdiel od neho však využíva OVELA viac pamäte na uloženie tabuľky tabu a tiež prehľadáva (generuje) viac génov.

> Python na hranenie 11 cisel od 1 do 11 potrebuje `28 B`(bytes). Tak potom na vyriešenie jednoduchej úlohy s 11 mestami je potrebných `108 KB` pamäte. A pre prvy moment z 101, kde on vygeneroval viac, ako 5 millionov: `145 MB`.

Ale nesmiem zabudnúť dodať, že moje nastavenia genetického algoritmu nemusia byť úplne efektívne.